Агрегаторы нейросетей с сильными бесплатными моделями для Telegram-бота

Критерии отбора

В обзор включены сервисы, которые:

- дают API-доступ к нескольким моделям/провайдерам ([redacted]ры или мульти-про[redacted]дерные платформы);
- имеют внятный бесплатный или условно бесплатный [redacted]статочный для pe[redacted]екта на бесплатном Render;
- хорошо подходят для LLM-чат-бота (приоритет), но [redacted]же дают картинк[redacted]о.

Основные метрики: качество и размер доступных модел[redacted]x/4, DeepSee[redacted]-OSS и т.п.), ограничения free-tier (RPM, RPD, токены), необходимость карты [redacted]enAI-совмес[redacted]PI и поддержка дополнительных фич (tools, JSON mode, streamin[redacted]

Краткий список рекомендованных агрега[redacted]

- OpenRouter — универсальный роутер к [redacted]лючая [redacted]weight и некоторые модели крупных вендоров) с отдельной подборк[redacted]ых м[redacted][1][2] [3][4]
- Together AI — клауд-хостинг >200 [redacted]бе[redacted]и и рядом моделей, помеченных как Free; OpenAI-со[redacted]
- DeepInfra — платформа infer[redacted]ma и др.) с стартовым бесплатным кредитом и Ope[redacted]
- Fireworks AI — фокус [redacted]товые бесплатные кредиты и несколько полностью [redacted]
- Hugging Face I[redacted]сяч моделей и к множеству провайдеров, [redacted]
- Groq Cl[redacted]янным бесплатным tier и Oper[redacted]27] [^28]
- [redacted].3, Llama 4 Scout,

Отдельно существуют «мета-агрегаторы» вроде сайтов free-[redacted]которые не дают свой API, но помогают находить провайдеры с бесплатными моделями.[6][11] [8][14] [^18]

Сравнительная таблица по ключевым параметрам

Сервис	Тип доступа	Бесплатные модели / кредиты	Нужна ли карта	OpenAI-совместимый chat API	Особенности для Telegram-бота
OpenRouter	API-роутер к множеству провайдеров	~29 полностью бесплатных моделей, в т.ч. Llama 3.3 70B, GPT-OSS 20B, Nemotron 3 Super; лимиты порядка 20 req/min и 200 req/day для free моделей[1][2] [^3]	Нет, для free моделей карту не требуют[1][2]	Да, синтаксис очень близок к OpenAI[33][1] [^3]	Удобно переключать модели одной точкой входа; есть фильтр по free-моделям и контексту, хорошо подходит для экспериментов и ранней версии бота.

Сервис	Тип доступа	Бесплатные модели / кредиты	Нужна ли карта	OpenAI-совместимый chat API	Особенности для Telegram-бота
Together AI	Платформа inference для open-source	$25 бесплатных кредитов для новых аккаунтов + десятки моделей помечены как Free (DeepSeek, Llama 3.3/4, Gemma и др.)[5][6][7][8][^9]	Обычно нет для стартовых кредитов; для более высоких лимитов может потребоваться[^7]	Да, API совместим с клиентами OpenAI[6][8]	Подходит для долгой эксплуатации за счёт дешёвых тарифов; есть reasoning- и vision-модели, tools, длинный контекст. Хороший кандидат на production, когда free-кредиты закончатся.
DeepInfra	Inference платформа	Стартовый бесплатный кредит около $5 с 90-дневным сроком; можно вызывать крупные модели вроде Meta-Llama-3.1-405B, Mixtral 8x22B, DeepSeek V3[10][11][12][13]	Нет для старта (регистрация через GitHub/email)[^11]	Да, endpoint полностью OpenAI-совместим[10][12][^13]	Хороший вариант для сравнения больших моделей на относительно небольшом бюджете; после исчерпания кредита потребуется платёжный метод.
Fireworks AI	Inference платформа, упор на скорость	Стартовые кредиты (~$1) + несколько моделей помечены как Free (Apriel 1.5/1.6 15B, Together MoA-1-Turbo и др.)[14][15][^17]	Для стартового кредита обычно не нужна; для продолжения — да[14][15]	Да, OpenAI-совместимый endpoint[15][17]	Хорош для теста быстрых моделей и structured-output; но free-ресурс небольшой, больше подходит для экспериментов и нагрузочного тестирования.
Hugging Face Inference API / Inference Providers	Единый API к тысячам моделей и к множеству провайдеров	Бесплатный rate-limited tier, даёт доступ к огромному количеству моделей, включая Llama 3.x, Qwen 2.5 72B, Gemma 2, Flux.1 и др.; часть моделей отмечена как free в рамках Inference Providers[18][19][20][21][22][23]	Нет, базовый free tier без карты[19][20][^22]	Есть OpenAI-совместимый chat endpoint в Inference Providers[^22]	Максимальный выбор моделей и задач (NLP, CV, audio); минусы — cold-starts и более сложный выбор конкретной модели; хорошо для специализированных кейсов и тестирования множества моделей.
Groq Cloud	Inference на собственных LPU-чипах	Постоянный бесплатный tier с ограничениями по RPM/TPM; акцент на Llama 3.x/4, Mixtral, DeepSeek и др., сверхвысокая скорость вывода (сотни токенов/сек)[24][25][26][27][^28]	Нет, free tier без привязки карты[25][28]	Да, OpenAI-совместимый формат[24][26][^27]	Отличен для Telegram-бота, где важен TTFB и скорость стрима; free-лимиты подходят для pet-проекта, но могут быть узкими для массового продакшна.

Сервис	Тип доступа	Бесплатные модели / кредиты	Нужна ли карта	OpenAI-совместимый chat API	Особенности для Telegram-бота
Cerebras Inference API	Inference на специализированных Cerebras-системах	Бесплатно до ~1M токенов в день по заявлению компании; доступ к Llama 3.3, Llama 4 Scout/Maverick, GPT-OSS-120B и другим моделям[29][30][31][32]	Судя по описанию free-тарифа, карта не требуется для начала[29][30]	Интерфейс OpenAI-подобный (через интеграции с Hugging Face и др.)[29][31]	Очень щедрый бесплатный лимит по токенам и высокая скорость; однако экосистема и документация менее массовы, чем у OpenAI-клонов, может быть чуть больше трения при интеграции.

Детальный

OpenRouter позиционируется как «единая точка входа» к десяткам моделей разных провайдеров (Google, Meta, Mistral, NVIDIA, OpenAI и др.) через один API-ключ и единый интерфейс. Сервис поддерживает выбор модели по идентификатору и маршрутизацию запросов между провайдерами без изменения клиентского кода.[3][1]

Отдельная коллекция free-models включает около 29 моделей на март 2026 года, среди которых Llama 3.3 70B, Nemotron 3 Super с контекстом до 262K токенов, GPT-OSS-20B и другие сильные open-weight модели; для их использования не требуется карта, но есть ограничения порядка 20 req/min и 200 req/day. Для Telegram-бота это даёт комфортный запас для личного использования или небольшого количества пользователей; при росте можно перенастроить ту же кодовую базу на платные модели, просто сменив модель-ID.[3][^1]

Together AI — клауд-платформа для запуска открытых моделей (Llama, DeepSeek, Mixtral, Gemma и многие другие) с OpenAI-совместимым API и serverless-GPU инфраструктурой. Платформа даёт новым пользователям бесплатные кредиты порядка $25 и поддерживает более 200 моделей, в том числе reasoning- и vision-варианты с большим контекстом (Llama 3.1 405B, Gemma 3, MiniMax M2 и др.).[8][5][^6]

Часть моделей отмечена как Free, а также есть специальные модели Apriel 1.5/1.6 Thinker с большим контекстом (131K токенов) и мультимодальными возможностями, доступные бесплатно на определённых тарифах. Ограничения free-услуг включают лимиты по RPM и токенам в минуту (напр., 60 RPM и 100K TPM для базового тарифа), чего достаточно для Telegram-бота с умеренным трафиком. Together хорошо подходит как универсальный backend: начинать на бесплатных кредитах и free-моделях, постепенно переходя к платному pay-as-you-go.[9][7]

DeepInfra даёт API к десяткам открытых LLM, включая Meta-Llama-3.1-405B-Instruct, Llama-3.1-70B, Mixtral-8x22B-Instruct, Qwen 2.5-72B и DeepSeek V3. API полностью совместим с OpenAI-клиентами и поддерживает стриминг, функцию calling, JSON-mode и интеграции с LangChain, LlamaIndex и др.[12][10]

Для новых пользователей предоставляется стартовый бесплатный кредит порядка $5 с ограниченным сроком действия (например, 90 дней), чего достаточно для тестирования и малонагруженного бота. Регистрация проста (email или GitHub) и не требует сразу указывать карту. DeepInfra удобно использовать как площадку для сравнения больших моделей по качеству и стоимости токена, а затем — как более дешёвую альтернативу крупных SaaS-LLM.[^11]

Firework. AI

Fireworks AI фокусируется на быстром inference open-source моделей (Llama, Qwen, DeepSeek и др.) и оптимизирован для агентных и структурированных нагрузок. Провайдер даёт небольшие стартовые кредиты (~$1) и несколько моделей, доступных бесплатно, включая Apriel 1.5/1.6 15B Thinker, Together MoA-1-Turbo и некоторые другие.[15][16] [17][14]

API совместим с OpenAI, а заявленные лимиты free-tier могут доходить до тысяч запросов в минуту и миллиардов токенов в день после добавления платёжного метода, хотя сами free-кредиты исчерпываются довольно быстро. Для Telegram-бота Fireworks целесообразен как площадка для краткого теста высокоскоростных моделей и нагрузочного профиля, но не как долгосрочно полностью бесплатный backend.[^14]

Hugging Face Inference API и Inference Provider.

Hugging Face предоставляет два ключевых механизма доступа к моделям по API:

- Inference API — прямой вызов конкретной модели из хаба по URL `https://api-inference.huggingface.co/models/<model>` с токеном доступа; для некоторых популярных моделей доступен бесплатный, но rate-limited режим.[19][18]
- Inference Providers / Chat endpoint — единый OpenAI-совместимый chat-endpoint, который проксирует запросы к множеству провайдеров и моделей; доступен бесплатный tier с кредитами и увеличенными лимитами для PRO-аккаунтов.[20][21] [22][19]

Примеры free-доступных моделей включают Llama 3.2 11B Vision-Instruct, Meta-Llama-3.1-8B-Instruct, Qwen 2.5-72B-Instruct, Gemma 2-9B и Flux.1-dev для картинок. Ограничения бесплатного использования выражаются в запросах/час (порядка сотен) и возможных cold-starts при обращении к непопулярным моделям. Для Telegram-бота это мощная «песочница» для специализированных задач (например, узкоспециализированные классификаторы или мультимодальные сценарии), но для стабильного чата с высокой частотой запросов лучше использовать более предсказуемые провайдеры.[18][20]

Groq Cloud

Groq Cloud предоставляет API к крупным open-source моделям (Llama 3.x, Llama 4 Scout/Maverick, Mixtral, DeepSeek и др.) на собственной аппаратной платформе LPU (Language Processing Unit), обеспечивающей скорости в сотни токенов/сек и очень низкую латентность. Free-tier у Groq постоянный по времени (это не trial), а ограничения выражаются в умеренных лимитах по RPM/TPM, достаточных для одиночных разработчиков и небольших проектов.[25][26] [27][28] [^24]

API совместим с форматом OpenAI Chat Completions, что позволяет почти без изменения кода мигрировать с других провайдеров. Для Telegram-бота, где критична скорость ответа и комфорт пользователя, Groq — один из лучших вариантов: можно стримить ответ с очень малым TTFB, используя бесплатный tier как демо или даже как backend для небольшого количества пользователей.[26][24]

Cerebra. Inference API

Cerebras открыла свой inference API с щедрым бесплатным лимитом — по сообщениям компании и профильных новостных ресурсов, разработчики могут получать до 1M токенов в день бесплатно, используя Llama 4, Llama 3.3, Qwen3 и другие модели. Сервис заявляет, что их специализированные системы обеспечивают скорость до 20 раз выше традиционных GPU-клаудов и тысячи токенов/сек на некоторых моделях.[30][31] [32][29]

Для старта достаточно зарегистрировать аккаунт и получить API-ключ, free-тариф описан как доступ к «всем Cerebras-powered моделям» с поддержкой сообщества через Discord. Интеграция с Hugging Face и Meta позволяет вызывать Cerebras через уже знакомые экосистемы. Для Telegram-бота это один из самых щедрых

му токенов, но возможны нюанс[illegible]ссовыми» [29] [^30]

[illegible]ые сервисы и мета-[illegible]

[illegible]иальные сайты-агрегаторы информации о бесплатных LLM API, такие как free-llm.com, freepertoken.com и аналогичные, которые:

- собирают в одном месте провайдеров (Together, DeepInfra, Fireworks, Hugging Face и др.) и указывают, есть ли у них free tier, требуются ли кредиты и карта;[6][8][illegible][14] [^18]
- показывают перечни моделей, которые можно вызывать бесплатно или на trial-кредиты, с их контекстом, возможностями (reasoning, vision, tools) и ценами в п[illegible]ных режимах.[7][6] [^14]

Эти ресурсы не дают собственного API для инференса модел[illegible] полезны как «карта местности», чтобы находить новые бесплатные площадки и актуальные изменения в тари[illegible]

Практические рекомендации для Telegram-бот[illegible]сплатном Render

1. **Начать с OpenRouter или Groq как базового L[illegible]nd.** Они дают простой OpenAI-совместимый API, позволяют выбр[illegible]ь сильную модель (Llama 3.3 7[illegible]SS-20B и др. для OpenRouter; Llama 3/4 и DeepSeek для Groq) и имеют понятный посто[illegible]ier без привязки карты.[3][28] [1][2] [24][25]
2. **Подключить T[illegible]ether или DeepInfra для [illegible]в с разными моделями и большими контекстами**, используя ста[illegible]ые кредиты и бесплатные [illegible] — дешёвый pay-as-you-go при росте нагрузки.[12][5] [7][11]
3. **Использов[illegible]gging Face Infere[illegible]изированных задач** (классификация, NER, специфич[illegible]timent, мультим[illegible]ывая отдельные модели через REST из вашего бэкенда на Rend[illegible] [^18]
4. **Для за[illegible]жна экстр[illegible]большие дневные квоты токенов**, рассмотреть Groq и Ce[illegible]сновные [illegible]дходят, если бот должен отвечать практически мгн[illegible]бать[illegible]нившейся бесплатности.[28][24] [29][30] [^31]

С учё[illegible]еречисленные сервисы поддерживают простой HT[illegible]нтегрировать через стандартные HTTP-клиенты на R[illegible]

[illegible]s on OpenRouter (March 2026) — 29 Free Models - Complete list of the best free models [illegible] in March 2026. 29 models, no credit card: Llama ...

[illegible]e Models: All 29 Listed (Apr 2026) - CostGoat - All free AI models on OpenRouter — zero [illegible]ard. Compare context lengths, capabilities,...

[illegible]on OpenRouter - Access powerful AI models at zero cost. Experiment, learn, and build [illegible]dels and LLMs. O...

[illegible]odels on OpenRouter: Technical Guide for ... - Apidog - Discover 13 top free AI models on [illegible]overing architectures, benchmarks, and real-world API ...

[illegible]ptfoo - Deploy open-source models at scale using Together AI's optimized inference platform with serverless ...

. Together.AI - Free LLM API - Complete guide to Together.AI's free tier. Generous limits, easy setup, and no credit card required.

[redacted]

its | Price ... - Together AI gives new users $25 in
00+ o dels, includin...

ls - Complete guide to Together.AI's free tier.
ed.

er.AI บริการคลาวด์ LLM เปิด Llama 3.3 70B ให้ใช้งาน

s using a simple API, pay per use. Low cost,

ra's free tier. Generous limits, easy setup, and no

12. Deepinfra over information about our machine learning model ...
13. De o access Open-source AI models such as Meta I
14. Fireworks A s, Credits & Limits - Fireworks AI offers $1 in free starter credits. Sr ast inference across...
15. Firewo uide to Fireworks AI's free tier. Generous limits, easy setup, and
1 und with Fireworks AI - A year ago, the only real LLM people rward to now, and there a...

rks AI for fast open model inference with AISCouncil

PI (2026) - Complete guide to Hugging Face Inference's free credit car...

500,000+ machine learning models via API. Run LLMs, , a...

Guide to Zero-Cost Inference - A comprehensive comparison of Google AI Studio and Groq to Op...

e - Unified API gateway for accessing AI models from multiple ugh bi...

for 1000+ AI ... - Surferstack - Hugging Face Inference Providers undreds of AI models across ...

g 2026: Is It Free? Complete Cost Breakdown - Is Hugging Face free? Yes! This 2026 ng Face pricing : free tier, PRO ($9/mo), Ente...

6 | Ultra-Fast LLM Inference - Guzli - Use Groq's LPU for the fastest LLM inference , supported models, free tier limit...

26: LPU Inference Costs Explained | DeployBase - Groq API pricing guide for 2026. s, billing models, cost optimization, and compari...

t LPU Inference for LLMs | AI Wiki - Complete Groq API guide covering LPU inference models, pricing tiers, Python SDK s...

ure: Ultra-Low Latency AI Inference | Introl Blog - Groq LPU delivering Llama 2 70B at faster than H100 clusters. Meta partnering wit...

28. Groq API Free Tier Limits in 2026: What You Actually Get - Groq API free tier limits in 2026: exact RPM, RPD, TPM, and TPD for every model including Llama 3.3,...

29. Cerebras Inference API Fully Opened: Developers Receive One ... - This free quota provides developers with ample resources to build and test high-performance AI appli...
30. Pricing - Cerebras - Inference API access ; Free. The easiest way to get started with Cerebras. Access to all Cerebras po...
31. Inference - Cerebras - Get Instant AI Inference. Experience blazing fast AI responses for code generation, summarization, a...
32. Cerebras - Blazing AI Inference powered by the. World's Fastest Processor ; Serve open models in seconds. Inclu...
33. How to Use AI Models API for Free | OpenRouter Tutorial - Want to Start Your Career in Tech or switch to another role? Try Scrimba’s interactive coding course...